



**BNP PARIBAS**  
La banque d'un monde qui change



# RAPPORT D'ACTIVITÉ 1

Réalisé par **Alin-Dorin PATA**

Mâitre de stage: **David WATERLOT**

Tuteur: **Laurent LAVAL**

Année : **BUT 2 - 2025-2026**

Lieu : **Reuil Malmaison**

Durée : **2 mois**

## 1. L'entreprise GAM Restaurant

### A. Sommaire

## Table des matières

|                                                                                       |    |
|---------------------------------------------------------------------------------------|----|
| 1. L'entreprise GAM Restaurant.....                                                   | 1  |
| A. Sommaire .....                                                                     | 1  |
| B. Structure et positionnement sur le marché .....                                    | 3  |
| C. Environnement de travail et organisation interne .....                             | 3  |
| D. Introduction du Stage.....                                                         | 4  |
| 2. Missions de départ.....                                                            | 4  |
| A. Présentation du dataset.....                                                       | 4  |
| B. Carte géographiques des restaurants .....                                          | 5  |
| C. Migration industrielle vers l'environnement Power BI.....                          | 7  |
| E. Recherche données météo API public .....                                           | 8  |
| 1. Portail météo France .....                                                         | 8  |
| 2. Modélisation statistique des seuils sous Python .....                              | 9  |
| 3. Interprétation des résultats sous Power BI .....                                   | 10 |
| 4. Optimisation de l'architecture : Migration vers un pipeline automatisé .....       | 11 |
| F. Analyse Power BI des couverts .....                                                | 11 |
| 1. Analyse approfondie des visualisations et mise en évidence de la saisonnalité..... | 12 |
| 3. Automatisation et Recherches d'informations .....                                  | 13 |
| A. Extraction code clients .....                                                      | 13 |
| B. Apprentissages automatiques avec Spacy .....                                       | 14 |
| C. Extraction informations fichier PDF en Excel .....                                 | 15 |
| D. Etude sur les frais de livraisons .....                                            | 18 |
| 4. Aboutissements .....                                                               | 21 |
| A. Conclusion.....                                                                    | 21 |
| B. Bibliographie.....                                                                 | 22 |
| C. Glossaire.....                                                                     | 23 |
| D. Annexes.....                                                                       | 25 |

## Remerciements

À M. David WATERLOT,

Pour m'avoir accueilli et suivi tout au long de ce stage et m'avoir donnée des missions de Data analyste et permis de découvrir de nouvelle façon de traiter la donnée et de l'utiliser et de comprendre les besoins d'une entreprise. Cela m'a permis de m'améliorer tout au long de mon stage.

À Mme. Laura POPESCU,

Pour m'avoir aidé à trouver mon stage au sein de l'entreprise, elle n'avait aucune obligation envers moi j'étais un simple inconnu et elle m'a quand même aidé à trouver ce stage très important.

À Mme. TORTI et Mme. CARDOSO

Pour leur aide et accompagnement dans ma recherche de stage.

À M. LAVAL et M. HÉBERT

Pour leurs cours de Programmation et Statistiques qui m'ont permis de réussir à mener à bien mes missions.

À M. LAVAL

Pour ses conseils pour la rédaction du rapport et la préparation de la soutenance ainsi que son accompagnement durant le stage.

À l'ensemble des membres du GAM Restaurant

Pour leur accueil et leur bienveillance tout au long de mon stage.

## B. Structure et positionnement sur le marché

**GAM Restaurant** est une Entreprise de Taille Intermédiaire (ETI) comptant environ 320 salariés. Filiale intégrée du groupe **BNP Paribas**, sa mission principale est la gestion de la restauration collective pour les collaborateurs du groupe et de ses partenaires.

L'entreprise a une vingtaine de restaurants répartis sur l'ensemble du territoire national, avec une forte concentration en Île-de-France ainsi qu'à Bordeaux. Cela montre l'adaptation constante de l'entreprise aux besoins immobiliers du groupe. Certains établissements ont récemment fermé leurs portes, tandis que de nouveaux espaces de restauration ont été ouverts.

L'offre de GAM Restaurant possède plusieurs formats de service afin de s'adapter à ses collaborateurs :

- Des **self-services** pour les repas principaux ;
- Des **snacks** pour une restauration rapide ;
- Des **cafétérias** pour les pauses et la vente à emporter.

Sur le plan de la performance, le restaurant **L'Odyssée** se distingue comme l'établissement le plus productif du réseau en termes de volume de couverts et d'activité quotidienne avec 1,7 million de repas servis (couverts) réalisés entre 2021 et 2026.

## C. Environnement de travail et organisation interne

L'environnement de travail au sein du siège social et des structures administratives est organisé pour la rapidité. Les bureaux sont organisés en **open spaces** (espaces de travail ouverts), avec des salles de réunion. Cette configuration spatiale a été choisie pour faciliter la communication directe et encourager la collaboration interservices.

L'entreprise est structurée autour de plusieurs directions qui communiquent entre elles pour répondre aux besoins internes et externes de l'entreprise :

1. **Le service Informatique (auquel j'ai été affecté) :** Il assure le support, la communication entre les différents services, la sécurité du groupe, les badges des différents collaborateurs, la gestion des infrastructures réseaux et l'analyse des données.
2. **Le service Comptabilité et Gestion :** Responsable de la facturation, du contrôle des coûts et des flux financiers.
3. **Le service Ressources Humaines (RH) :** En charge de la gestion des collaborateurs, des compétences et des recrutements.
4. **Le service Qualité :** Garant du respect strict des normes d'hygiène, de sécurité alimentaire et de la satisfaction des usagers.
5. **Le service Achats :** Responsable de l'approvisionnement des matières premières et de la négociation des contrats avec les fournisseurs.

Cette organisation est collaborative. Les services ne travaillent pas de manière isolée : selon la nature des projets et des besoins, le service informatique est régulièrement amené à collaborer étroitement avec les autres pôles. C'est dans ce cadre collaboratif que s'est inscrit mon stage, où j'ai notamment développé des solutions techniques (scripts d'automatisation et de traitement de données) répondant directement aux besoins de l'entreprise.

## D. Introduction du Stage

Au cours de ce stage d'une durée de huit semaines, s'étant déroulé du 20 avril au 18 juin 2026 au sein de la filiale **GAM Restaurant du groupe BNP Paribas** à Rueil-Malmaison, j'ai occupé la fonction d'**Assistant Data Analyst**.

L'objectif de ma mission est la donnée, depuis son nettoyage à sa valorisation. Pour GAM Restaurant, l'enjeu stratégique majeur réside dans la production d'une **donnée de haute qualité : la moins biaisée possible, nettoyée et structurée**, afin de pouvoir être exploitée de manière fiable par les différentes directions opérationnelles. En effet, dans le secteur de la restauration collective, des données erronées ou incomplètes peuvent lourdement impacter la décision de l'entreprise, exploitant environ 40 % des données.

Pour répondre à cette problématique, mon rôle a consisté à concevoir et utilisé des script de traitement automatisés, mais également à réaliser des analyses exploratoires et descriptives. J'ai fait ces analyses à travers la création de **tableaux de bord interactifs (dashboards)** et de visualisations graphiques.

L'idée fondamentale de mon intervention était d'apporter un ajustement à l'entreprise en fonction de ses projets du moment. En m'ajustant continuellement aux processus déjà en place, j'ai dû trouver des solutions d'optimisation (pipelines de données connectés aux API, scripts d'extraction OCR), à travers des outils comme Python, globalement, comme l'entreprise a son propre espace réseau et ses propres outils, le choix était limité en termes de technologie. C'est pour cela que je me suis orienté dans l'utilisation de Python, qui est polyvalent et très facilement intégrable au système du GAM.

## 2. Missions de départ

### A. Présentation du dataset

Le *dataset* brut se présentait sous la forme d'un tableau de données relationnelles contenant plusieurs variables complémentaires.

Afin d'en assurer une exploitation statistique, ces variables ont été répertoriées, nettoyées voici un aperçu des différentes variables :

- **Bâtiment** : Variable qualitative nominale identifiant de manière unique chaque restaurant du réseau (ex. : *L'Odyssée*).

- **Activité** : Variable décrivant le type de service rattachée au point de vente (Self, Snack, Cafétéria).
- **Adresse** : Variable contenant la localisation postale du restaurant
- **Coordonnées GPS** : Latitude et Longitude
- **Période** : Variable chronologique (format Date) pour l'axe temporel de l'étude. Elle permet de structurer les séries temporelles pour suivre l'évolution des données de fréquentation.
- **Nombre de couverts par jour** : Variable quantitative représentant l'indicateur clé de performance (KPI).

| NC_id_IM | IMPRINC_IMMEUBLE_NOM_USAGE                   | CDPF | latitude  | longitude | station_meteo_id | station_meteo_nom | IMPRINC_ADRESSE_REF_LIG   | ZDP_COMPRINC_VILLE_NOM | Nb_UID | urant |
|----------|----------------------------------------------|------|-----------|-----------|------------------|-------------------|---------------------------|------------------------|--------|-------|
| 100000   | Valmy 1                                      | 19   | 48,852691 | 2,418988  | 75114001         | PARIS             | 59 Rue de la Republique   | 93100 MONTREUIL        | 2227   | Oui   |
| 100002   | 16 Italiens                                  | 35   | 48,871778 | 2,337854  | 75114001         | PARIS             | 16 Boulevard des Italiens | 75009 PARIS            | 426    | Oui   |
| 100023   | 1 Haussmann                                  | 16   | 48,872087 | 2,338386  | 75114001         | PARIS             | 1 Boulevard Haussmann     | 75009 PARIS            | 601    | Oui   |
| 100226   | Sofia                                        | 17   | 48,884842 | 2,348331  | 75114001         | PARIS             | 8 Rue de Sofia            | 75018 PARIS            | 1063   | Oui   |
| 104709   | VALMY 2                                      | 21   | 48,850631 | 2,417397  | 75114001         | PARIS             | 33 RUE DE VALMY           | 93100 MONTREUIL        | 1685   | Oui   |
| 105593   | Rueil l'Europeen Bat B                       | 5    | 48,889663 | 2,16799   | 75114001         | PARIS             | 6 Rue Auguste Perret      | 92500 RUEIL-MALMAISON  | 421    | Oui   |
| 106185   | Rueil 2 Gares                                | 23   | 48,890574 | 2,176459  | 75114001         | PARIS             | 22 Rue des Deux Gares     | 92500 RUEIL-MALMAISON  | 2111   | Oui   |
| 107136   | Le Palais du Hanovre                         | 9    | 48,870224 | 2,334161  | 75114001         | PARIS             | 16 Rue de Hanovre         | 75002 PARIS            | 961    | Oui   |
| 107137   | VALMY 4                                      | 32   | 48,851336 | 2,416093  | 75114001         | PARIS             | 48 RUE Claude ERIGNAC     | 93100 MONTREUIL        | 1330   | Oui   |
| 113733   | GMP                                          | 11   | 48,89755  | 2,39689   | 75114001         | PARIS             | 9 Rue du Debarcadere      | 93500 PANTIN           | 3762   | Oui   |
| 116798   | Odyssee                                      | 14   | 48,893461 | 2,178891  | 75114001         | PARIS             | 8 Rue du Port             | 92000 NANTERRE         | 4587   | oui   |
| 117238   | APAC - Tassigny                              | 13   | 48,853691 | 2,492511  | 75114001         | PARIS             | 207 Rue Carnot            | 94120 FONTENAY-SOUS-BK | 1113   | Oui   |
| 117548   | CLAUDE BERNARD ALLEGRO                       | 34   | 48,89901  | 2,377335  | 75114001         | PARIS             | 160 BOULEVARD MACDONALD   | 75019 PARIS 19         | 1225   | Oui   |
| 118283   | MAC 19                                       | 24   | 48,898584 | 2,377664  | 75114001         | PARIS             | 163 Boulevard MACDONALD   | 75019 PARIS 19         | 1960   | Oui   |
| 121279   | COMPANS                                      | 26   | 48,896512 | 2,398584  | 75114001         | PARIS             | 3 RUE du General COMPANS  | 93500 PANTIN           | 861    | Oui   |
| 121671   | Unicity                                      | 28   | 48,896222 | 2,281238  | 75114001         | PARIS             | 141 Rue Anatole France    | 92300 LEVALLOIS-PERRET | 3329   | Oui   |
| 125782   | Rueil L'Europeen Bat A                       | 5    | 48,889643 | 2,167991  | 75114001         | PARIS             | 4 Rue Auguste Perret      | 92500 RUEIL-MALMAISON  | 119    | Oui   |
| 126063   | Merignac Alizee - Ariane 31                  | 27   | 44,834703 | -0,686945 | 33281001         | BORDEAUX          | 31 Avenue Ariane          | 33700 MERIGNAC         | 394    | Oui   |
| 126064   | Merignac Iris - Ariane 31                    | 27   | 44,834703 | -0,686945 | 33281001         | BORDEAUX          | 31 Avenue Ariane          | 33700 MERIGNAC         | 447    | Oui   |
| 126065   | BATIMENT HEXAGONE 106 AVENUE DU PRESIDENT JF | 27   | 44,834946 | -0,690071 | 33281001         | BORDEAUX          | 106 AVENUE DU PRESIDENT   | 33700 MERIGNAC         | 1167   | Oui   |
| 126107   | MILLENAIRE 4                                 | 31   | 48,872965 | 2,379601  | 75114001         | PARIS             | 35 RUE DE LA GARE         | 75019 PARIS 19         | 2081   | Oui   |
| 128952   | Valmy 8                                      | 33   | 48,851087 | 2,426361  | 75114001         | PARIS             | 93 Rue Marceau Immeuble I | 93100 MONTREUIL        | 1130   | Oui   |

## B. Carte géographiques des restaurants

La première étape de mon travail consistait à concevoir une carte interactive à partir de zéro, afin de spatialiser les données de fréquentation. L'objectif technique était de pouvoir analyser visuellement et au cours du temps le nombre de couverts répartie sur les différents bâtiments de l'entreprise.

Pour ce faire, j'ai développé une interface web dynamique en utilisant les technologies standards du Web :

```
index.html X JS script.js # style.css
index.html > ...
1 <!DOCTYPE html>
2 <html lang="fr">
3 <head>
4   <meta charset="utf-8" />
5   <title>Carte bâtiments</title>
6
7   <link
8     href="https://cdn.jsdelivr.net/npm/bootstrap@5.3.3/dist/css/bootstrap.min.css"
9     rel="stylesheet"
10  />
11
12   <link rel="stylesheet" href="./style.css" />
13
14   <script src="https://unpkg.com/papaparse@5.4.1/papaparse.min.js"></script>
15   <script src="./script.js" defer></script>
16 </head>
17
18 <body>
19   <div class="app">
20     <aside class="sidebar p-3">
21       <h4 class="mb-1">Evolution des couverts par Bâtiments</h4>
22       <p class="text-muted small mb-4"></p>
23
24       <div class="mb-3">
25         <label for="buildingSelect" class="form-label fw-semibold">Choisir un bâtiment</label>
26         <select id="buildingSelect" class="form-select">
27           <option value="">Tous les bâtiments</option>
28         </select>
29       </div>
30     </aside>
  
```

- **HTML** : Pour structurer la page de l'application et intégrer les conteneurs nécessaires à l'affichage de la carte ;
- **CSS** : Pour concevoir une interface utilisateur (UI), assurant le design visuel et l'adaptation ergonomique de la page ;
- **JavaScript** : Pour gérer l'aspect dynamique, la manipulation du Document Object Model, l'intégration de bibliothèques cartographiques open-source, l'injection dynamique des marqueurs GPS issus du dataset.

Afin de rendre cet outil d'analyse performant pour les utilisateurs métiers, j'ai développé et implémenté deux filtres de requête interactifs :

## Evolution des couverts par Bâtiments


Choisir un bâtiment

Tous les bâtiments

Période

04/01/2021

17/04/2026



1. **Un filtre nominatif** : Permettant d'isoler instantanément un bâtiment spécifique ou un restaurant du réseau pour analyser ses statistiques propres ;
2. **Un filtre temporel (période)** : Permettant de faire évoluer dynamiquement l'affichage pour observer l'historique et les fluctuations des couverts sur des fenêtres temporelles choisies.


Cette première phase a permis de valider la faisabilité algorithmique du projet et de mettre en évidence la distribution géographique des points de restauration.

### C. Migration industrielle vers l'environnement Power BI

Dans un second temps, afin d'industrialiser ce prototype et de l'intégrer au sein d'un écosystème décisionnel plus robuste et facilement utilisable j'ai fait une migration technique complète vers la solution de Business Intelligence **Microsoft Power BI**.

Cette phase de transition a requis plusieurs opérations techniques :

- **L'intégration cloud via Microsoft Azure** : J'ai lié l'environnement Power BI avec les services de géolocalisation Azure Maps afin d'assurer un rendu visuel fluide et précis des cartes géographiques, éliminant les contraintes de maintenance du code JavaScript.
- **La modélisation des filtres décisionnels** : J'ai reconstruit de manière native les filtres interactifs sous forme de segments dynamiques (filtre par nom de bâtiment et filtre par période). Ces segments interagissent instantanément avec les cartes et les indicateurs clés de performance (KPI) associés.



Cette double mission peut perdre à l'entreprise un outil d'aide à la décision, permettant aux gestionnaires de suivre en quelques clics l'évolution temporelle des volumes de couverts, d'identifier les pics de fréquentation par infrastructure.

## E. Recherche données météo API public

### 1. Portail météo France

Afin de pousser plus loin l'analyse prédictive et descriptive des facteurs influençant la fréquentation des restaurants, l'entreprise a souhaité croiser le jeu de données d'origine avec l'historique météorologique quotidien des zones géographiques concernées. L'enjeu opérationnel était d'identifier si des corrélations stables existaient entre les conditions climatiques et la production de couverts afin d'anticiper les volumes de matières premières à commander.

Pour réaliser cet tâche, je me suis connecté à la plateforme officielle « Météo-France »

**RÉPUBLIQUE FRANÇAISE**

**MÉTÉO FRANCE**

**MÉTÉO FRANCE**  
NOS API EN LIGNE

Recherche des api

[Accueil](#) > [DonneesPubliquesClimatologie](#) > [Configurer l'API](#)

**CONFIGURER L'API DONNÉES CLIMATOLOGIQUES** v1

**Télécharger le swagger**

**TYPE DE TOKEN**

☒ OAuth2 ☐ API Key

**DURÉE DE VALIDITÉ**

1 heure

Token

**Générer Token**

L'exploration du portail de Météo-France a d'abord permis de gérer la sécurité (jetons OAuth2), d'analyser la documentation technique (Swagger) et d'isoler une alternative sans code via le téléchargement direct de fichiers CSV. Cependant, cette approche manuelle a été écartée car elle aurait imposé une charge de nettoyage de données beaucoup plus lourde et répétitive à chaque mise à jour. C'est pourquoi j'ai privilégié la propreté et l'automatisation d'un script Python : après avoir configuré l'authentification sécurisée, j'ai développé un programme capable d'extraire automatiquement l'historique complet de l'année voulue ex : 2021 à 2026 pour chaque station météorologique rattachée

**GET** `/commande-station/quotidienne` commande la création du fichier TEXTE (CSV) des données climatologiques pour tous les paramètres disponibles, à la fréquence quotidienne, pour une station, sur la profondeur de date demandée

renvoie le n° de commande dans le corps (structuré – JSON) de la réponse

**Parameters** Essayer

| Name                                                                 | Description                                                                                                                                                                                                                                                                                                           |
|----------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>id-station</b> * required<br>string<br>(query)                    | identifiant de la station. Nomenclature : 8 chiffres selon DDCCCN (métropole) ou DDDCCN (outre-mer) avec insee de la commune (DD département, CCC n° de la commune dans le département de métropole ou DDD département, CC n° de la commune dans le département d'outre-mer) et NNN n° de la station dans la commune. |
| <b>date-deb-periode</b> * required<br>string(\$date-time)<br>(query) | date de début de période pour la commande (au format ISO 8601 avec TZ UTC : AAAA-MM-JJT00:00:00Z)                                                                                                                                                                                                                     |
| <b>date-fin-periode</b> * required<br>string(\$date-time)<br>(query) | date de fin de période pour la commande (au format ISO 8601 avec TZ UTC : AAAA-MM-JJT23:59:59Z)                                                                                                                                                                                                                       |


## 2. Modélisation statistique des seuils sous Python

Les données brutes retournées par l'API présentaient un volume d'indicateurs continus qu'il a fallu nettoyer, nommer et catégoriser pour les rendre exploitables. La jointure finale entre le *dataset* de fréquentation et les données climatiques a été réalisée via la variable DATE.

```
def classifieur_meteo(row):
    if row["NEIGE"] > 0:
        return "NEIGE"
    if row["ORAGE"] > 0:
        return "ORAGE"
    if row["PLUIE"] > 0:
        return "PLUIE"
    if row["SOLEIL"] >= 1905:
        return "ENSOLEILLE"
    return "NUAGEUX"
```

Pour simplifier l'analyse décisionnelle, j'ai développé un algorithme de classification sur mesure sous Python (utilisant la bibliothèque *Pandas*) permettant de traduire les variables continues en 5 variables qualitatives : NEIGE, ORAGE, PLUIE, ENSOLEILLE ou NUAGEUX.

- **1. Phénomènes rares (Prioritaires dans l'algorithme) :**
  - **NEIGE** : Activé dès l'apparition des premiers flocons.
  - **ORAGE** : Exige une activité électrique et sonore continue sur l'ensemble de la journée (différencié d'un éclair isolé).
- **2. PLUIE** : Déclenché dès qu'il y a des précipitations.
- **3. ENSOLEILLÉ** : Activé lorsque le rayonnement solaire global est supérieur ou égal à 1905 J/cm<sup>2</sup>. Ce seuil scientifique correspond au **3ème quantile (75%)** de la distribution, permettant d'isoler les 25% de journées les plus lumineuses de la période.
- **4. NUAGEUX** : Représentant donc les journées nuageuses.



### 3. Interprétation des résultats sous Power BI

Une fois le jeu de données météo consolidé et stocké sous forme de table, je l'ai importé dans Power BI pour concevoir des visualisations croisées analytiques (courbes d'évolutions temporelles, graphiques en barres et diagrammes circulaires).

L'analyse montre un comportement d'achat contre-intuitif au sein du réseau de GAM Restaurant : **près de 50 % du volume global des couverts est réalisé durant les journées de PLUIE**. Si l'on pouvait instinctivement penser que le mauvais temps réduirait l'activité, cette statistique s'explique de manière logique par le positionnement de l'entreprise : implantés sur des sites de bureaux (immeubles captifs), les collaborateurs privilégient les structures de restauration interne (selfs, cafeterias de l'immeuble) en cas d'intempéries afin de ne pas quitter leur bâtiment, tandis que les journées ensoleillées favorisent l'évasion vers des solutions de restauration

externes. De plus, les analyses ont réaffirmé que le restaurant **L'Odyssee** conserve sa position de leader en termes de volume de production, indépendamment de la météo.

#### 4. Optimisation de l'architecture : Migration vers un pipeline automatisé


Pour finir cette mission, j'ai identifié et corrigé une vulnérabilité au sein de l'infrastructure de traitement. Initialement, l'architecture reposait sur un cycle manuel : les données étaient extraites et stockées localement sur les postes de travail, puis importées manuellement dans Power BI. Ce processus n'était pas optimal et source d'erreurs d'intégration.

Afin de fluidifier et d'automatiser cette chaîne de valeur, j'ai conçu et déployé une architecture Cloud intégrée :

1. **Migration Cloud** : L'ensemble des données a été centralisé au sein d'un répertoire partagé sécurisé sur **Google Drive**.
2. **Industrialisation du Script** : Le script Python de traitement API a été déployé en local afin de garantir le contrôle du script.
3. **Flux Continu sous Power BI** : J'ai reconfiguré la source de données de mon tableau de bord Power BI en y injectant l'URL Web du Google Sheet hébergé.

Désormais, l'architecture est totalement autonome : chaque nouvelle exécution du script Python interroge l'API, met à jour le fichier cloud sur le Drive, et alimente de manière transparente les graphiques du tableau de bord sans aucune intervention humaine requise.

#### F. Analyse Power BI des couverts



## 1. Analyse approfondie des visualisations et mise en évidence de la saisonnalité

L'intégration du tableau de bord interactif sous Power BI (illustré par la figure ci-dessus) permet d'analyser de manière croisée la fréquentation des restaurants, le climat et l'évolution temporelle des flux. L'étude des différents graphiques révèle des tendances comportementales claires ainsi qu'une forte saisonnalité au cours de l'année.

- **Répartition des couverts par typologie météorologique** : Le diagramme circulaire confirme de manière chiffrée l'impact des intempéries sur le comportement des collaborateurs. Les journées de PLUIE représentent à elles seules **50 %** du volume total des couverts, suivies par les journées de NUAGE (**33 %**). À l'inverse, les journées ENSOLEILLÉ ne captent que **17 %** du volume. Cela valide statistiquement l'hypothèse : en cas de météo défavorable, les salariés réduisent leurs déplacements extérieurs et se reportent massivement sur l'offre de restauration interne de GAM Restaurant.
- **Analyse de la saisonnalité temporelle (Évolution des couverts)** : Le graphique linéaire mesurant l'évolution du nombre de couverts sur l'axe du temps montre une **saisonnalité cyclique**, directement liée au rythme de l'activité d'un groupe de bureaux (BNP Paribas) :
  - **Les creux saisonniers majeurs (Périodes estivale et hivernale)** : On observe une chute drastique et systématique de la fréquentation durant les mois de juillet et d'août, ainsi qu'en fin d'année (décembre). Ces creux correspondent parfaitement aux périodes de congés annuels des collaborateurs.
  - **Les pics d'activité (Printemps et Automne)** : À l'inverse, les phases de forte reprise (septembre-octobre et mars-avril-mai) affichent des sommets de fréquentation. Ces périodes coïncident avec une présence maximale des équipes sur site et avec des conditions météo plus instables (notamment les épisodes de pluie printaniers et automnaux).
- **Hiérarchie de performance des infrastructures** : Le graphique en barres horizontales réaffirme la prédominance de l'établissement *L'Odysée*, qui se positionne en tête du réseau ce qui surpasse largement les autres structures.

En conclusion, ce croisement de données démontre que la fréquentation ne dépend pas uniquement du calendrier civil, mais qu'elle possède une double composante saisonnière : d'une part, le calendrier de présence des collaborateurs sur site (congés/télétravail) et, d'autre part, la saisonnalité climatique où la pluie agit comme un accélérateur direct de performance pour la restauration collective interne.

### 3. Automatisation et Recherches d'informations

#### A. Extraction code clients

**Note de confidentialité :** Par souci de stricte confidentialité et afin de préserver l'anonymat des clients du groupe, les identités (noms et prénoms) présentées dans cette section ont été générées artificiellement. Néanmoins, l'ingénierie algorithmique et la technique de reconnaissance textuelle présentées restent strictement identiques à celles déployées sur le jeu de données réel.

Dans le cadre de cette première sous-mission, l'objectif consistait à isoler et à extraire de manière totalement automatisée le code de facturation de chaque client. Face aux 200 lignes de texte brut et non structuré de la colonne adresse, j'ai mené une phase d'analyse exploratoire pour identifier des régularités mathématiques exploitables.

| Adresse_fact_saisie                        | Centre Cout |
|--------------------------------------------|-------------|
| COMMANDE PERSONNEL / PAR VIREMENT          | 39215       |
| BNPP_BCEF 59245 Antoine Morel              | 59245       |
| BNPP_BCEF ENTREPRISE COO 81975             | 81975       |
| PAR VIREMENT BANCAIRE                      | 31066       |
| BCEF RETAIL BNPP RET 31066                 | 31066       |
| RHU - BCEF RH 31253 Thomas                 | 31253       |
| BNPP_PPA 38270 Claire Fontaine             | 38270       |
| BNPP_BCEF Transformation Agile             |             |
| BNPP_RET BCEF RETAIL Julien                |             |
| BNPP1CAPP TSA 10001                        |             |
| 03380 RESSOURCES ET COORD                  | 3380        |
| BNP PARIBAS WEALTH MGMT                    |             |
| DITA Innovation & Acceleration             |             |
| BNPP_BCEF - REGION IDF EST                 |             |
| BNP PARIBAS WEALTH MGMT                    |             |
| Hello Bank 81963 Laurent Giraud            | 81963       |
| 03380 SERVICE CLIENT BCEF                  | 3380        |
| BCEF RETAIL BNPP_RET 31066                 | 31066       |
| BNPP_BCEF - REGION IDF EST                 |             |
| BNP Paribas SA BNPP_PPA 38270 Julie Moreau | 38270       |
| 03380 RESSOURCES ET COORD                  | 3380        |
| ALM TRESORERIE 3 rue d'Antin               |             |
| BNPP_BCEF Transfo Agile                    |             |

#### Conception et logique de l'algorithme

: L'étude des données a révélé une structure répétitive pour cette variable spécifique : le code de facturation était entouré de deux retours chariot (\n) et se composait la plupart du temps d'une suite de cinq caractères numériques. En m'appuyant sur ces contraintes de format, j'ai développé un script en Python utilisant les expressions régulières (**Regex**). Le motif de recherche a été configuré pour cibler précisément cette séquence de cinq chiffres isolés par des sauts de ligne.

- **Analyse des résultats et bilan quantitatif :**

L'application de cet algorithme sur l'échantillon des 200 profils clients a donné des bons résultats :

- **160 codes de facturation** ont été automatiquement extraits, nettoyés et intégrés avec succès dans la base finale, sans aucune erreur de ciblage (80% du jeu de données).
- **20 clients** ont été identifiés comme ne possédant aucun code de facturation au sein de la chaîne de caractères. Une vérification a permis de comprendre que ces comptes correspondaient à des d'utilisateurs réglant leurs prestations directement par virement bancaire.

- **20 profils restants** présentaient des anomalies ou des ruptures de structure plus lourdes dans la chaîne textuelle brute. Afin de garantir l'exhaustivité de la base, j'ai procédé à un traitement manuel pour ces derniers.
- **Conclusion :**

L'utilisation des expressions régulières s'est avérée être la solution idéale pour cette tâche. Grâce à la uniformité du format cible (la règle des 5 chiffres), l'algorithme a offert un excellent taux de fiabilité et une exécution instantanée, sécurisant ainsi l'extraction de la grande majorité des identifiants de facturation du réseau.

## B. Apprentissages automatiques avec Spacy

Si l'extraction des codes numériques par expressions régulières s'est avérée robuste, la récupération automatique de l'identité des clients (noms et prénoms) a constitué le défi technique majeur de cette mission. Contrairement aux codes de facturation, les données nominatives ne suivaient aucun format géométrique ou syntaxique fixe au sein de la colonne adresse, rendant l'utilisation d'une méthode déterministe (par règles strictes) totalement inefficace.

| Clients          | Prénom    | Nom       |  |
|------------------|-----------|-----------|--|
| Antoine Morel    | Antoine   | Morel     |  |
| Sophie Caron     | Sophie    | Caron     |  |
| Camille Renaud   | Camille   | Renaud    |  |
| Nicolas Dupuis   | Nicolas   | Dupuis    |  |
| Thomas Garnier   | Thomas    | Garnier   |  |
| Claire Fontaine  | Claire    | Fontaine  |  |
| Élodie Marchand  | Élodie    | Marchand  |  |
| Julien Lefèvre   | Julien    | Lefèvre   |  |
| François Delmas  | François  | Delmas    |  |
| Marie Robert     | Marie     | Robert    |  |
| Lucie Bernard    | Lucie     | Bernard   |  |
| Alexandre Petit  | Alexandre | Petit     |  |
| Pierre Chevalier | Pierre    | Chevalier |  |
| Pierre Chevalier | Pierre    | Chevalier |  |
| Lucie Bernard    | Lucie     | Bernard   |  |
| Laurent Giraud   | Laurent   | Giraud    |  |
| Nathalie Mercier | Nathalie  | Mercier   |  |
| Nicolas Dupuis   | Nicolas   | Dupuis    |  |
| Julie Moreau     | Julie     | Moreau    |  |
| Pierre Chevalier | Pierre    | Chevalier |  |
| Élodie Marchand  | Élodie    | Marchand  |  |
| Marie Robert     | Marie     | Robert    |  |
| Arthur Lemoine   | Arthur    | Lemoine   |  |
| Arthur Lemoine   | Arthur    | Lemoine   |  |

- **Implémentation technologique avec spaCy (Algorithme NLP) :**

Pour faire face à cette variabilité textuelle, j'ai mis en place une approche probabiliste basée sur le traitement automatique du langage naturel (NLP). J'ai configuré un script Python s'appuyant sur la bibliothèque spécialisée **spaCy** et chargé son modèle linguistique français optimisé pour le traitement de texte général : `fr_core_news_sm`.

- **Analyse approfondie des difficultés rencontrées :**

Malgré la pertinence théorique de cette approche IA, l'application du modèle sur le terrain a révélé d'importantes limites et une forte instabilité opérationnelle, caractérisée par un taux de réussite d'environ **60 % (soit 120 identités correctement récupérées sur 200)**. Les principales difficultés techniques rencontrées sont les suivantes :

- **Les bruits et ambiguïtés de contexte (Confusions d'étiquettes) :** Le modèle d'apprentissage générique a fréquemment confondu les noms de familles ou les prénoms avec d'autres dimensions textuelles présentes dans la même cellule. Par exemple, certains noms de rues ou de communes ou des noms de prestataires de services ont été faussement étiquetés en entités PER au lieu d'entités géographiques (LOC) ou d'organisations (ORG).
- **La casse et les ruptures de syntaxe (Données mal formatées) :** Les modèles NER s'appuient fortement sur la présence de majuscules et la structure de la phrase pour détecter les noms propres. Or, dans notre fichier source, de nombreuses identités étaient écrites entièrement en minuscules, tronquées, ou noyées au milieu de caractères spéciaux. Privé de repères syntaxiques propres, l'algorithme n'a pas détecté ces entités, entraînant un volume élevé de faux négatifs (noms non détectés).
- **Le phénomène de sur-segmentation :** Dans certaines configurations complexes, le script n'a extrait qu'une partie de l'entité (le prénom seul ou le nom seul).
- **Bilan et ajustements manuels :**

Sur l'échantillon complet, les **80 profils** restants 40% ont dû être fait manuellement. Cette phase a consisté à inspecter visuellement chaque chaîne de caractères résiduelle pour corriger les erreurs de spaCy ou saisir manuellement les identités manquantes. Cette expérience démontre que si les bibliothèques NLP sur étagère fournissent un excellent point de départ, elles s'avèrent insuffisantes face à des données réelles d'entreprise fortement dégradées et semi-structurées, confirmant ainsi le besoin de basculer vers des modèles plus avancés (modèles de langage spécialisés ou apprentissage supervisé dédié) pour l'envisager au big data.

### C. Extraction informations fichier PDF en Excel

Cette mission avait pour objectif d'automatiser l'extraction des informations contenues dans un catalogue au format PDF afin de constituer une base de données exploitable sous Excel. Le catalogue regroupait de nombreux produits de restauration, chacun étant présenté avec un nom, des caractéristiques commerciales et une description détaillée. Selon les cas, les informations relatives à un même produit pouvaient s'étendre sur plusieurs pages.

Exemple de produit :



| BUFFET TABLE D'EXCEPTION<br>AVEC DÉGUSTATIONS CHAUDES                                                                                                                                                  |                                                                                                                                                                                                                       |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Base 25 personnes, dressage sur plateau maître/assiettes et ardoises<br><sup>(1)</sup> Prévoir des petites fourchettes ou couteaux, penser à son linge                                                 |                                                                                                                                                                                                                       |
| Nos produits sont susceptibles d'être modifiés ou remplacés par un produit équivalent en matière de qualité et de fraîcheur de nos approvisionnements                                                  |                                                                                                                                                                                                                       |
| <b>Bretzel</b><br>1 dégustation<br>- Chiffonnade de volaille au corné ACP                                                                                                                              | <b>Boite black &amp; white<sup>(1)</sup></b><br>1 dégustation<br>- Moelleux de volaille issue de Label Rouge ou curry à l'ancienne, pommes fondantes<br>- Daurade à la crème d'estragon, petits pois en deux textures |
| <b>Demi bun's and roll feuilleté</b><br>1 dégustation<br>- Saumon fumé, crème de raifort, batavia et oignon rouge mariné au vinaigre                                                                   | <b>Tea time<sup>(1)</sup></b><br>1 dégustation<br>- Financier pistache et confit de coing sureau                                                                                                                      |
| <b>Bocaux<sup>(1)</sup></b><br>1 dégustation<br>- Savarin de poivrons marinés au quinoa, crevettes à l'ail                                                                                             | <b>Macarons classiques</b><br>1 dégustation                                                                                                                                                                           |
| <b>Brochettes cocktail sur assiette consignée</b><br>Sur bandoulière   1 dégustation<br>- Serrano 510 <sup>®</sup> , figue moelleuse, pain d'épices<br>- Magret fumé, oignon confit, lacets de carotte | <b>Verrine pulpe<sup>(1)</sup></b><br>1 dégustation<br>- Perles du Japon au lait de coco et mangue                                                                                                                    |
| <b>Salade Ota<sup>(1)</sup></b><br>1 dégustation<br>- Matelardines à la mozzarella et tomates ardequin                                                                                                 | <b>OPTION SUPPLÉMENTAIRE :</b><br><b>Sélection du maître fromager</b><br>Pain de campagne tranche   50 g                                                                                                              |

BUFFET  
DEBOUT

J'ai commencé par identifier automatiquement les différents produits présents dans le catalogue. Pour cela, j'ai analysé la structure du document afin de repérer les titres correspondant aux noms des produits. Certains intitulés généraux servant uniquement à organiser le catalogue (catégories ou rubriques) ont été exclus afin de ne conserver que les véritables produits.

Une fois les produits détectés, j'ai regroupé l'ensemble du contenu associé à chacun d'eux. Cela a permis de reconstruire les fiches produits même lorsque celles-ci étaient réparties sur plusieurs pages. Pour chaque produit, j'ai ensuite séparé les informations en deux catégories :

- Les caractéristiques commerciales
- La description détaillée du produit.

Afin d'améliorer la qualité des résultats, plusieurs règles ont été mises en place pour reconnaître automatiquement les formats les plus courants utilisés dans le catalogue. Les informations extraites ont ensuite été vérifiées et dédoublées afin d'éviter les répétitions.

Grâce à cette automatisation, il a été possible d'extraire directement **32 produits sur les 73 présents dans le catalogue**. Ces produits partageaient une structure homogène permettant leur détection et leur traitement automatiques par le script. En revanche, les **41 produits restants présentaient des mises en page ou des formats de présentation différents**, ce qui empêchait une extraction fiable et automatisée. Leur intégration dans le fichier final a donc nécessité traitement manuel afin de garantir l'exactitude et l'exhaustivité des données.



Enfin, l'ensemble des informations a été structuré dans un fichier Excel comportant une ligne par produit et plusieurs colonnes dédiées au nom du produit, à ses caractéristiques et à sa description.

| Reference | Nom                          | Caracteristiques                               | Description                                         |
|-----------|------------------------------|------------------------------------------------|-----------------------------------------------------|
| AV        | ATELIERS VÉGÉTAUX            | Nos commerciaux sont à votre disposition pour  | Atelier rouleau végétalVendu par rouleau de 10 dé   |
| ASA       | ANIMATIONS SALÉES            | Suggestions d'animations pour vos événement    | Printemps – ÉtéAnimation club sandwich ° Des sa     |
| ASU       | ANIMATIONS SUCRÉES           | Suggestions d'animations pour vos événement    | Animation glace° Des mini-cornets sucrés enrob      |
| T         | TENTATIONS                   | Commande minimum de 16 pièces par variété      | Cookie* chèvre, mangue et fruit de la passion,Gyc   |
| BRC       | BROCHETTES COCKTAIL          | Commande minimum de 20 pièces par variété      | Tomate confite, mozzarella, ruban de courgette,Tc   |
| PT        | PIÈCES TRADITION             | Commande minimum de 20 pièces par variété      | Mini blinisBlinis au thé matcha° Rilletes de langou |
| M         | MOZZARELLA                   | Contenant en verre consigné(1), 100 g   Comm   | Mozza, tomates et petits pois,Mozza, tomates et o   |
| PS        | PETITES SALADES              | Salade composée en « tasse Ola »(1)   Comma    | Jeu de tomates et mozzarella au basilic, 95 gQuinc  |
| S         | SALADES                      | Nos produits sont susceptibles d'être modifiés | Salade végétaleSaladier de 10 personnes° Salade     |
| VP        | VERRES PRIVILÈGES            | Commande minimum de 20 pièces par variété      | Carotte, crème fumée, oignons frits,Crèmeux de c    |
| LC        | LES CÉRAMIQUES               | Commande minimum de 20 pièces par variété      | Les céramiques brouillade d'œufs° Brouillade d'o    |
| LBV       | LES BULLES VÉGÉTALES         | Commande minimum de 20 pièces par variété      | Douceur de butternut au poivre du Timut, chantilly  |
| LBAC      | LES BOÎTES À CAVIAR          | Commande minimum de 20 pièces par variété      | Crèmeux de petits pois à la menthe glaciale et ricc |
| LPPDM     | LES PETITS POTS DU MARAÎCHER | Commande minimum de 20 pièces par variété      | Lentilles belluga liées au houmous de carotte au c  |
| LGDP      | LES GAUFRES DU POTAGER       | Commande minimum de 20 pièces par variété      | Saumon fumé, brocoli et crèmeux citron sur gauf     |
| G         | GOURMANDISES                 | Commande minimum de 20 pièces par variété      | Le chou litchi rose,Comme une tartelette framboi    |
| CDV       | COCKTAIL DOLCE VITA          | 20 pièces. Base 25 personnes, 6 pièces cocktz  | Tentations sur assiette consignée8 pièces ° Dôme    |
| CRDA      | COCKTAIL ROSÉE D'AZUR        | 18 pièces. Base 25 personnes, 6 pièces cocktz  | Tentations sur assiette consignée7 pièces ° Dôme    |
| CDDM      | COCKTAIL DOUCEUR DU MIDI     | 15 pièces. Base 25 personnes, 6 pièces cocktz  | Tentations sur assiette consignée6 pièces ° Dôme    |
| CRDI      | COCKTAIL RÊVE D'INSTANT      | 12 pièces. Base 25 personnes, 6 pièces cocktz  | Tentations sur assiette consignée6 pièces ° Dôme    |
| CBDS      | COCKTAIL BULLE DE SOLEIL     | 12 pièces. Base 25 personnes, 6 pièces cocktz  | Canapés saveurs4 pièces° Muffin de chèvre roma      |
| CDA       | COCKTAIL DOUCE AUREOLE       | 10 pièces. Base 25 personnes, 6 pièces cocktz  | Tentations sur assiette consignée4 pièces° Dôme     |
| CSDÉ      | COCKTAIL SOUFFLE D'ÉTÉ       | 10 pièces. Base 25 personnes. 6 pièces cocktz  | Canapés saveurs5 pièces° Muffin de chèvre roma      |

Cette mission a permis de combiner automatisation et contrôle manuel afin d'obtenir une base de données complète et fiable. L'utilisation du script a considérablement réduit le temps nécessaire à la saisie des informations tout en assurant une extraction cohérente pour les produits respectant le format standard du catalogue.

#### D. Etude sur les frais de livraisons

**Note de confidentialité :** Par souci de stricte confidentialité des données financières du groupe, les visuels de factures insérés dans ce rapport sont des modèles d'illustration anonymisés. Néanmoins, l'ingénierie algorithmique développée est universelle et conçue pour s'exécuter sur n'importe quelle facture du réseau.

#### 1. Logique d'ingénierie du script d'extraction automatique

Pour traiter le flux massif de 2 579 factures mensuelles, j'ai développé un pipeline d'extraction automatisé sous Python. L'originalité technique de cette solution repose sur l'utilisation combinée de la manipulation de fichiers PDF et d'un moteur de Reconnaissance Optique de Caractères (OCR) performant : l'infrastructure **RapidOCR** (basée sur l'environnement d'exécution ONNX Runtime).

Exemple de facture :

| SHIP TO:                      |                               | BILL TO:                                                                                                 |  | Shipping method: <b>Ground</b> |  |
|-------------------------------|-------------------------------|----------------------------------------------------------------------------------------------------------|--|--------------------------------|--|
| Name: <b>J.C. Tornton</b>     | Name: <b>J.C. Tornton</b>     | For invoice inquiries please e-mail to: <a href="mailto:sales@qlcomputers.com">sales@qlcomputers.com</a> |  |                                |  |
| Address: <b>25, Oxford Rd</b> | Address: <b>25, Oxford Rd</b> |                                                                                                          |  |                                |  |
| City: <b>Toronto</b>          | City: <b>Toronto</b>          |                                                                                                          |  |                                |  |
| State: <b>ON</b>              | State: <b>ON</b>              |                                                                                                          |  |                                |  |
| Zip: <b>M2M 4B9</b>           | Zip: <b>M2M 4B9</b>           |                                                                                                          |  |                                |  |
| Phone: <b>1 416 777 77</b>    | Phone: <b>1 416 777 77</b>    |                                                                                                          |  |                                |  |

| Item # | ITEM CODE  | ITEM DESCRIPTION                                                                                                       | Qty | PRICE         | AMOUNT   | COMMENTS                   |
|--------|------------|------------------------------------------------------------------------------------------------------------------------|-----|---------------|----------|----------------------------|
| 1      | P35-S609   | TOSHIBA Satellite P35-S609 P4-M-538(3.2)/512/80/DVDMulti/WiFi/ WinXP/17"1440x900                                       | 2   | 1 926.00      | 3 852.00 | TOSHIBA Satellite Notebook |
| 2      | NOKIA 7610 | NOKIA 7610 Silver Grey (900/1800/1900, LCD 176x208@64k, GPRS+Bluetooth, int.antenna, video, MMS, Li-ion 900mAh, 118r.) | 1   | 515.00        | 515.00   |                            |
| Items  |            |                                                                                                                        | 3   | Sub-total     | 4 367.00 |                            |
|        |            |                                                                                                                        |     | Sales tax 15% | 655.05   |                            |
|        |            |                                                                                                                        |     | TOTAL         | 5 022.05 |                            |

Payment terms:

a) Payment Method:

- Online payment at [www.QLComputers.com](http://www.QLComputers.com), OR
- Cheque payable to QL Computers Ltd.

b) Payment is due within 60 days of the invoice date

With Kind Regards,

Sales Department  
QL Computers Ltd.

L'algorithme suit une séquence logique pour chaque document :

1. **La numérisation géométrique :** Le script ouvre le fichier PDF via la bibliothèque PyMuPDF (fitz) et convertit la première page du document en une matrice de pixels (un

tableau NumPy à trois dimensions : hauteur, largeur, canaux de couleur) à une résolution optimisée (DPI) selon le fournisseur.

2. **La détection spatiale par boîte d'ancrage** : Le moteur RapidOCR scanne l'image pour détecter les blocs de texte. Pour chaque mot trouvé, il génère une boîte de coordonnées géographiques bidimensionnelles (X, Y) sur la page, le texte associé, ainsi qu'un score de confiance statistique.
3. **L'alignement horizontal dynamique** : Dès que le mot-clé cible du fournisseur est repéré (ex: "*DEPLACEMENT*", "*PRESTATION DE TRANSPORT*"), l'algorithme mémorise la coordonnée verticale de référence. Il regarde ensuite l'ensemble des autres boîtes de texte pour regrouper toutes celles situées sur la même ligne.
4. **Le tri positionnel et l'extraction de l'indice** : Les éléments détectés sur cette ligne virtuelle sont triés de gauche à droite selon leur coordonnée horizontale. Grâce à un système d'indexation inversé (ex : l'indice -2), le script extrait précisément la valeur numérique du prix associée à la prestation, en ignorant les variations d'alignement ou des bruits textuels. Les résultats sont enfin structurés dans un tableau *Pandas* puis exportés au format Excel.

#### Description et analyse du jeu de données final des frais de livraison :

Résultats de la facture simuler :

| fournisseur | facture     | prestation | prix   |
|-------------|-------------|------------|--------|
| PC          | invoice.pdf | NOKIA 7610 | 515.00 |

Résultats des factures réel :

| A             | B             | C          | D                       | E        |
|---------------|---------------|------------|-------------------------|----------|
| Nom           | N° Facture    | Date       | Motif                   | Prix (€) |
| Fournisseur 1 | STD-P-2015141 | 01/04/2026 | PRESTATION DE TRANSPORT | 15 €     |
| Fournisseur 1 | STD-P-2015142 | 03/04/2026 | PRESTATION DE TRANSPORT | 20 €     |
| Fournisseur 1 | STD-P-2015143 | 05/04/2026 | PRESTATION DE TRANSPORT | 30 €     |
| Fournisseur 1 | STD-P-2015144 | 07/04/2026 | PRESTATION DE TRANSPORT | 15 €     |
| Fournisseur 1 | STD-P-2015145 | 09/04/2026 | PRESTATION DE TRANSPORT | 20 €     |
| Fournisseur 1 | STD-P-2015146 | 11/04/2026 | PRESTATION DE TRANSPORT | 15 €     |
| Fournisseur 1 | STD-P-2015147 | 13/04/2026 | PRESTATION DE TRANSPORT | 20 €     |
| Fournisseur 1 | STD-P-2015148 | 15/04/2026 | PRESTATION DE TRANSPORT | 15 €     |
| Fournisseur 1 | STD-P-2015149 | 17/04/2026 | PRESTATION DE TRANSPORT | 20 €     |
| Fournisseur 2 | STD-P-2015150 | 01/04/2026 | PRESTATION DE TRANSPORT | 70 €     |
| Fournisseur 2 | STD-P-2015151 | 03/04/2026 | PRESTATION DE TRANSPORT | 70 €     |
| Fournisseur 2 | STD-P-2015152 | 05/04/2026 | PRESTATION DE TRANSPORT | 70 €     |
| Fournisseur 2 | STD-P-2015153 | 07/04/2026 | PRESTATION DE TRANSPORT | 70 €     |
| Fournisseur 2 | STD-P-2015154 | 09/04/2026 | PRESTATION DE TRANSPORT | 70 €     |
| Fournisseur 2 | STD-P-2015155 | 11/04/2026 | PRESTATION DE TRANSPORT | 70 €     |
| Fournisseur 2 | STD-P-2015156 | 13/04/2026 | DEPLACEMENT             | 70 €     |
| Fournisseur 2 | STD-P-2015157 | 15/04/2026 | DEPLACEMENT             | 70 €     |
| Fournisseur 2 | STD-P-2015158 | 17/04/2026 | DEPLACEMENT             | 70 €     |
| Fournisseur 2 | STD-P-2015159 | 19/04/2026 | DEPLACEMENT             | 70 €     |
| Fournisseur 2 | STD-P-2015160 | 21/04/2026 | DEPLACEMENT             | 70 €     |

L'exécution OCR a permis de consolider une base de données propre et exploitable, isolant l'ensemble des lignes de facturation liées au transport (comme illustré par les extraits de tables des figures associées).

Le jeu de données structuré obtenu comprend les dimensions techniques et métiers suivantes :

- **La dimension d'identification** : Elle se compose des variables fournisseur et facture (le nom de fichier unique du PDF d'origine servant de traçabilité).
- **La variable prix** : Cette variable quantitative continue stocke le montant unitaire extrait des frais de livraison.

| Synthèse des Frais de Livraison par Fournisseur |            |                |                |                |
|-------------------------------------------------|------------|----------------|----------------|----------------|
| Nom                                             | nb facture | % des factures | prix           | % du prix      |
| Fournisseur 1                                   | 9          | 10,59%         | 250 €          | 8,79%          |
| Fournisseur 2                                   | 35         | 41,18%         | 1 820 €        | 63,97%         |
| Fournisseur 3                                   | 13         | 15,29%         | 215 €          | 7,56%          |
| Fournisseur 4                                   | 28         | 32,94%         | 560 €          | 19,68%         |
| <b>Total général</b>                            | <b>85</b>  | <b>100,00%</b> | <b>2 845 €</b> | <b>100,00%</b> |

L'analyse de cet export final compte 85 **factures** contenant effectivement des coûts de livraison, représentant un total **2 845 €**. Cela offre à l'entreprise une visibilité sur ses coûts de livraison de nature contractuelle.

## 4. Aboutissements

### A. Conclusion

Ce stage de huit semaines, effectué au sein du service Informatique de GAM Restaurant, filiale du groupe BNP Paribas, a constitué une étape importante dans mon parcours de futur Data Scientist. Au-delà de l'application purement technique de concepts informatiques, cette expérience m'a poussé à développer une posture professionnelle axée sur l'adaptabilité, l'autonomie et la collaboration.

### Journal de bord de résolution et enseignements

La mise en œuvre de la valeur de la donnée m'a confronté aux réalités du terrain, souvent bien éloignées de la théorie des bases de données idéales. L'intégration de technologies avancées a révélé des limites concrètes : un taux de réussite plafonné à 60 % pour la reconnaissance des entités nommées avec *spaCy*, ou encore l'extraction automatique restreinte à 32 produits sur 73 dans le catalogue PDF.

Face à ces blocages technologiques, mon journal de bord s'est transformé en un outil de pilotage stratégique :

1. **Analyse de cause racine** : Identifier précisément pourquoi l'algorithme échouait (manque de majuscules pour *spaCy*, ruptures de structures graphiques pour *RapidOCR*).
2. **Adaptation** : Lorsque l'automatisation totale était impossible, j'ai mis en place des processus hybrides, combinant un pré-nettoyage algorithmique et une phase de complémentation manuelle.
3. **Autonomie** : Pendant 8 semaines, j'ai dû travailler pour la recherche d'une solution algorithmique, et pour l'efficacité (le traitement manuel) des tâches. Ces missions m'ont montré que la data science n'est pas parfaite et que la plupart du temps les données sont biaisées, non-structurées ou très fragmentées ce qui rend l'analyse de la donnée très difficile et en conséquence faudra s'adapter au différent contexte.

### Évolution des compétences et intégration personnelle

Ce stage m'a permis une évolution dans ma capacité à lier les connaissances théoriques du BUT à des problématiques industrielles complexes. Si j'ai débuté mes missions en adoptant un réflexe purement technique (écriture de scripts de manière isolée), j'achève ce parcours avec une vision globale de l'entreprise.

Mon intégration au sein de l'équipe informatique m'a permis de comprendre que la donnée n'est pas une entité abstraite : elle impacte directement le contrôle de gestion, la comptabilité et les achats.

En conclusion, ce projet m'a permis de développer les compétences nécessaires pour aborder le traitement de données sous un usage industriel. Les compromis trouvés face aux imperfections des fichiers réels m'ont appris qu'un bon Data Analyst n'est pas seulement un technicien qui code, mais un traducteur capable de transformer des flux de données complexes en informations exploitables pour l'entreprise.

## B. Bibliographie

### 1. Environnements de Business Intelligence et Services Cloud

- Microsoft Azure. (2026). *Azure Maps Services – Intégration de couches de données géospatiales et rendus cartographiques*. Microsoft Corporation. <https://learn.microsoft.com/fr-fr/azure/azure-maps/>
- Microsoft Power BI. (2026). *Documentation officielle Power BI – Conception de tableaux de bord décisionnels, modélisation relationnelle et flux de données automatisés*. Microsoft Corporation. <https://learn.microsoft.com/fr-fr/power-bi/>
- Google Workspace. (2026). *Google Drive API & Google Sheets Service – Centralisation Cloud de bases de données et synchronisation continue*. Google Cloud. <https://developers.google.com/sheets/api>

### 2. Écosystème Google Maps Platform & Cartographie (Cloud & JS)

- Google Cloud. (2026). *Google Maps JavaScript API – Déploiement de cartes dynamiques interactives, gestion des calques (Layers) et intégration de scripts côté client*. Google Developers. <https://developers.google.com/maps/documentation/javascript>
- Google Cloud. (2026). *Geocoding API – Service de conversion de chaînes de caractères textuelles (adresses de restaurants) en coordonnées géographiques (Latitude, Longitude)*. Google Maps Platform. <https://developers.google.com/maps/documentation/geocoding>
- Flanagan, D. (2020). *JavaScript: The Definitive Guide: Master the World's Most Used Programming Language* (7e éd.). O'Reilly Media. (Utilisé pour la manipulation des objets Map, l'asynchronisme async/await lors des appels d'API et l'injection dynamique dans le DOM).

### 3. Interfaces de Programmation (API Publics)

- Météo-France. (2026). *Portail API Météo-France – Documentation technique (Swagger) et accès sécurisé (OAuth2) aux données climatologiques de base*. Direction générale de Météo-France. <https://portail-api.meteofrance.fr/>

### 4. Bibliothèques de Traitement de Données et Statistiques (Python)

- McKinney, W., & the Pandas Development Team. (2026). *Pandas: Powerful data structures for data analysis, manipulation and time series toolkits in Python*. PyData. <https://pandas.pydata.org/docs/>
- Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). *Array programming with NumPy*. Nature, 585(7825), 357–362. <https://numpy.org/doc/>

## 5. Bibliothèques d'Intelligence Artificielle et Traitement du Langage Naturel (NLP)

- Explosion AI. (2026). *spaCy: Industrial-strength Natural Language Processing in Python (Modèle linguistique pré-entraîné fr\_core\_news\_sm et algorithme Named Entity Recognition)*. <https://spacy.io/usage/linguistic-features>

## 6. Moteurs d'Ingénierie Documentaire et Reconnaissance Optique de Caractères (OCR)

- McKie, J., & PyMuPDF Contributors. (2026). *PyMuPDF (fitz) Documentation – Manipulation de fichiers vectoriels PDF et rendu matriciel de pixels*. Artifex Software. <https://pymupdf.readthedocs.io/>
- RapidAI Team. (2026). *RapidOCR: Ultra-fast and lightweight OCR system based on ONNX Runtime environment*. Open-Source Software. <https://github.com/RapidAI/RapidOCR>

## 7. Formats de Fichiers et Échanges de Données

- Van Rossum, G. (2026). *The re module – Regular Expressions (Regex) operation library for Python string parsing*. Python Software Foundation. <https://docs.python.org/3/library/re.html>

## C. Glossaire

### 1. Lexique (Restauration Collective & Secteur Bancaire)

- **Immeuble captif** : Bâtiment de bureaux ou site d'entreprise dont les collaborateurs ont de la restauration immédiate à l'intérieur de leurs espaces de travail.
- **Couvert** : Unité de mesure de l'activité en restauration collective correspondant à un repas complet servi à un client sur une journée.
- **Self-service** : Format de restauration en libre-service où l'utilisateur compose lui-même son plateau parmi plusieurs entrées, plats chauds et desserts.
- **Snack / Cafétéria** : Espaces de restauration rapide intégrés ou périphériques, proposant une offre de vente à emporter ou de consommation légère (sandwichs, salades, cafés, viennoiseries).

### 2. Lexique Data

- **Dataset** : Bases de données permettant de regrouper de l'information.
- **KPI** : Indicateur Clé de Performance.

- **Quantile (3ème Quantile / 75%)** : Mesure statistique de position divisant une série de données triées en quatre parts égales. Le 3ème quantile indique la valeur en dessous de laquelle se situent 75 % des observations et au-dessus de laquelle se trouvent les 25 % des valeurs les plus élevées.
- **Variable qualitative** : Variable non numérique qui exprime une catégorie ou une qualité.
- **Variable quantitative** : Variable numérique mesurable.
- **spaCy** : Bibliothèque open-source avancée en langage Python dédiée au Traitement Automatique du Langage Naturel (TALN / NLP), conçue pour une utilisation industrielle et permettant d'analyser de grands volumes de textes.
- **NER (Named Entity Recognition)** : Reconnaissance d'Entités Nommées. Sous-discipline de l'intelligence artificielle et du NLP consistant à développer un algorithme capable de repérer et de classer des entités textuelles dans un texte brut sous des étiquettes prédéfinies, telles que des noms de personnes (PER), des lieux (LOC), ou des organisations (ORG).
- **Tokenisation** : Processus informatique consistant à découper une chaîne de caractères textuelle brute en unités linguistiques minimales appelées "tokens" (mots, ponctuation, chiffres) pour permettre leur analyse par un modèle NLP.
- **Format semi-structuré** : Forme de données textuelles qui ne respecte pas la structure stricte d'une base de données relationnelle (tables, colonnes), mais qui contient néanmoins des marqueurs ou des invariants sémantiques internes permettant de séparer grossièrement les informations.

### 3. Lexique Automatisation, OCR et Cloud Integration

- **API (Application Programming Interface)** : Interface de programmation permettant à deux applications informatiques distinctes de communiquer et d'échanger des données de manière automatisée et sécurisée.
- **Jetons (Tokens)** : Protocole standard de sécurité et d'authentification permettant à une application tierce d'accéder aux ressources d'un serveur via un jeton d'accès temporaire chiffré, évitant ainsi d'exposer les identifiants d'origine.
- **Swagger** : Ensemble d'outils open-source s'appuyant sur l'architecture REST, permettant de décrire, de documenter et de tester la structure technique d'une API (les URL, les paramètres d'entrée et les formats de sortie JSON/CSV) directement depuis une interface web.
- **OCR (Optical Character Recognition)** : Reconnaissance Optique de Caractères. Technologie informatique permettant de transcrire l'image d'un texte imprimé ou manuscrit (comme une facture au format PDF ou image) en texte encodé numériquement et exploitable par un traitement de données.

- **RapidOCR** : Moteur d'OCR open-source ultra-léger et rapide optimisé pour s'exécuter au sein de l'environnement ONNX Runtime, utilisé pour localiser et transcrire les blocs de texte sur les factures de livraison.
- **DPI (Dots Per Inch)** : Points par pouce. Unité de mesure de la résolution d'une image. Plus le DPI est élevé (ex. : 500 DPI), plus la précision graphique est forte mais plus le temps de calcul machine augmente.
- **Regex** : Chaînes de caractères de contrôle décrivant un motif de recherche textuel (pattern). Elles permettent de vérifier la conformité d'une chaîne ou d'y extraire des fragments spécifiques selon des règles mathématiques strictes.
- **Power BI** : Outil d'informatique décisionnelle développé par Microsoft, conçu pour centraliser, modéliser, analyser et restituer visuellement des données d'entreprise sous forme de tableaux de bord interactifs d'aide à la décision.
- **Pipeline de données** : Suite logique d'étapes de traitement automatisées appliquées aux flux de données, comprenant la collecte (extraction API/OCR), le nettoyage (Python/Pandas), le stockage (Cloud/Google Drive) et la restitution visuelle (Power BI).

## D. Annexes

### 1. Script de récupération des données météo par API.


```
import time
import requests
import pandas as pd
from io import StringIO
from datetime import datetime, timedelta

SERVER = "https://public-api.meteofrance.fr/public/DPClim/v1"
TOKEN = "eyJ4NXQ1OiJZV0kxTTJZNE1qWTNOemsyTkRZeU5XTTRPV014TXpjk1UVmhNbU14T1RSa09ETX1OVEE0Tnc9PSIsImtpZCI6ImdhbGV3YX1fY2VydGlmakN"
headers = {"apikey": TOKEN}
stations = {
    "PARIS": "75114001",
    "BORDEAUX": "33281001"
}
annee_debut = 2021
today = datetime.today()
hier = today - timedelta(days=1)
periodes = []
for annee in range(annee_debut, today.year + 1):
    debut = f"{annee}-01-01T00:00:00Z"
    if annee == today.year:
        fin = hier.strftime("%Y-%m-%dT23:59:59Z")
    else:
        fin = f"{annee}-12-31T23:59:59Z"
    periodes.append((debut, fin))
all_data = []
for nom_station, station_id in stations.items():
    print(f"\n{nom_station} -> {station_id}")
    for date_deb, date_fin in periodes:
        print(f"Période : {date_deb} -> {date_fin}")
        r_cmd = requests.get(
            f"{SERVER}/commande-station/quotidienne", headers=headers, params={
                "id-station": station_id,
                "date-deb-periode": date_deb,
                "date-fin-periode": date_fin, timeout=5
            })
        r_cmd.raise_for_status()
        id_commande = (r_cmd.json()["elaboreProduitAvecDemandeResponse"])[0]["return"]
        time.sleep(1)
        r_file = requests.get(f"{SERVER}/commande/fichier", headers=headers, params={"id-cmde": id_commande}, timeout=5)
        if r_file.status_code in [200, 201] and "POSTE;DATE" in r_file.text:
            df = pd.read_csv(StringIO(r_file.text), sep=";", decimal=",")
            df["VILLE"] = nom_station
            all_data.append(df)
            time.sleep(1)
if not all_data:
    raise Exception("Aucune donnée récupérée.")
df = pd.concat(all_data, ignore_index=True)
df["DATE"] = pd.to_datetime(df["DATE"], format="%Y%m%d", errors="coerce")
df_final = (df[["POSTE", "VILLE", "DATE", "RR", "NEIG", "ORAG", "GLOT"]].sort_values(["POSTE", "DATE"]).reset_index(drop=True))
df_final.to_csv("Meteo_PB.csv", index=False, encoding="utf-8-sig")
print("CSV créé : Meteo_PB.csv")
```

## Documentation :

| Code     | Paramètre Météo-France                  | Unité           | Seuil Algorithmique Python (GAM)               |
|----------|-----------------------------------------|-----------------|------------------------------------------------|
| AAAAMMJJ | date de la mesure                       | année mois jour | Clé primaire de jointure relationnelle         |
| RR       | quantité de précipitation tombée en 24h | mm              | PLUIE si > 0 mm (Priorité 3)                   |
| GLOT     | rayonnement global quotidien            | J/cm²           | ENSOLEILLÉ si ≥ 1905 J/cm² (3e quantile / 75%) |
| NEIG     | occurrence de neige (0: non, 1: oui)    | code (0/1)      | NEIGE si == 1 (Priorité 1)                     |
| ORAG     | occurrence d'orage (0: non, 1: oui)     | code (0/1)      | ORAGE si == 1 (Priorité 2)                     |

## Frais de livraison dossier :



## Exemple des données de départ en XML

```
<agr:Invoice>
  <agr:InvoiceNo>999999</agr:InvoiceNo>
  <agr:Header>
    <agr:LineNo>1</agr:LineNo>
    <agrlib:InvoiceDate>2026-01-01</agrlib:InvoiceDate>
    <agr:OrderRef>8888888</agr:OrderRef>
    <agr:ArchivePath>..\Data Files\agresso\Data Import\STD-P-00000000-000000-0000
    <agr:InvoiceText>STD-P-00000000-000000-000000</agr:InvoiceText>
    <agr:Currency>EUR</agr:Currency>
    <agr:Seller>
      <agrlib:SellerNo>000000</agrlib:SellerNo>
    </agr:Seller>
    <agr:Buyer>
      <agrlib:CompanyCode>XX</agrlib:CompanyCode>
    </agr:Buyer>
  </agr:Header>
  <agr:Summary>
    <agr:TotalExclTax>100.00</agr:TotalExclTax>
    <agr:TotalTax>20.00</agr:TotalTax>
    <agr:TotalInclTax>120.00</agr:TotalInclTax>
  </agr:Summary>
</agr:Invoice>
```

Script regroupant tout les pdf dans un seul dossier :

```
import shutil
from pathlib import Path

# 1. On prépare la liste de tous les noms de PDF à rechercher
fichiers_rech = set()
for cell in df_res["fichiers"].dropna():
    fichiers = str(cell).split(";")
    for f in fichiers:
        fichiers_rech.add(f.strip())

# 2. On parcourt le dossier "Facture" pour trouver ces PDF
racine = Path("Facture")
pdf_utile = []
for pdf in racine.rglob("*.pdf"):
    if "BB" in pdf.parts: # On exclut les dossiers contenant BB
        continue
    if pdf.stem in fichiers_rech:
        pdf_utile.append(pdf)

# 3. On crée le dossier unique de destination
dossier_destination = Path("PDF_Code")
dossier_destination.mkdir(exist_ok=True)

# 4. On regroupe TOUS les PDF dans ce seul dossier
for chemin in pdf_utile:
    shutil.copy2(chemin, dossier_destination / chemin.name)
```

Script qui regroupe les pdf par fournisseur :

```
import shutil
from pathlib import Path

# 1. Définition des dossiers source et destination
source = Path("PDF_Code")
destination_parent = Path("Pdf_Fournisseurs")

# 2. Boucle sur chaque ligne du tableau de résultats pour trier les fichiers
for i in df_res.index:
    # Récupération et nettoyage du code fournisseur
    fournisseur_code = str(df_res.loc[i, "code_fournisseur"]).strip()


    # Création du sous-dossier spécifique pour ce fournisseur
    dossier_fournisseur = destination_parent / fournisseur_code
    dossier_fournisseur.mkdir(parents=True, exist_ok=True)

    # Récupération de la liste des fichiers associés à ce fournisseur
    liste_pdfs = str(df_res.loc[i, "fichiers"]).split(";")

    # Parcours et copie de chaque fichier trouvé dans le dossier source
    for nom_fichier in liste_pdfs:
        nom_fichier = str(nom_fichier).strip()
        fichier_source = source / f"{nom_fichier}.pdf"

        # Vérification si le fichier existe bien avant de le copier
        if fichier_source.exists():
            shutil.copy2(fichier_source, dossier_fournisseur / fichier_source.name)
```

Arborescence des dossiers créer :



Performances d'un pc Intel 5 sans carte graphique :



Performances d'un pc Ryzen 7 avec carte graphique RTX 4060:

